Primera Entrega: Sistema bayesiano de recomendación de películas

---

Integrantes: Sebastián Baldovino - 2243565 / Laura Ortiz - 2243553 / Santiago Marín - 2243556

Curso: Métodos de Inferencia Bayesiana

Docente: David Edmundo Romo Bucheli

Institución: Universidad Industrial de Santander.

Fecha: 7 de octubre de 2026

1. Formulación del problema

1.1 Contexto, relevancia y fuentes de incetidumbre

Los sistemas de recomendación constituyen una de las aplicaciones más relevantes del aprendizaje automático moderno. Plataformas de entretenimiento como Netflix y Spotify, y comercio electrónico dependen de ellos para personalizar la experiencia del usuario. En el núcleo de estos sistemas se encuentra un problema estadístico fundamental: predecir la preferencia o calificación de un usuario para un ítem no observado, a partir de una matriz de interacciones incompleta y de alta dimensión.

En este dominio existen dos fuentes principales de incertidumbre que dificultan la estimación:

1. Incertidumbre epistémica (de los parámetros):
   Derivada de la escasez de datos por usuario o por ítem. Para usuarios nuevos o películas poco populares, la información disponible es insuficiente para determinar con precisión sus preferencias o atributos latentes.
2. Incertidumbre aleatoria (observacional):
   Asociada a la variabilidad intrínseca en el comportamiento humano al calificar, la cual está sujeta a factores contextuales no observados (estado de ánimo, momento del día, sesgos de escala individuales).

1.2 Cantidades de interés y justificación de la metodología bayesiana

Los parámetros latentes del modelo: los sesgos globales, de usuario e ítem (μ, b_u, b_i), así como los vectores de factores latentes (U_u, V_i) que caracterizan los gustos de los usuarios y las propiedades de las películas.

La distribución predictiva posterior: la distribución de probabilidad de la calificación no observada $\hat{Y}_{u,i}$ para un par usuario-ítem dado, condicional en los datos observados Y_{obs}.

La inferencia bayesiana constituye la metodología adecuada para abordar este problema debido a las siguientes razones:

Manejo de la dispersión y regularización a priori: mediante el uso de distribuciones a priori, se incorpora una regularización natural que evita el sobreajuste en usuarios o ítems con pocas calificaciones.

Cuantificación completa de la incertidumbre: a diferencia de los métodos deterministas de factorización matricial, el enfoque bayesiano no proporciona solo una estimación puntual, sino la distribución posterior completa de las predicciones. Esto permite evaluar la confiabilidad de una recomendación antes de presentarla al usuario.

Incorporación de métodos de simulación MCMC: permite realizar inferencia sobre parámetros multidimensionales complejos mediante algoritmos de muestreo como Gibbs Sampling o MCMC, integrando incertidumbre en todas las etapas del modelado.

1.3 Descripción de los datos, fuente y disponibilidad

Para el desarrollo y evaluación del modelo se utilizará el conjunto de datos MovieLens 100K (ml_100k_u.data), recolectado por el grupo de investigación GroupLens de la Universidad de Minnesota (https://grouplens.org/datasets/movielens/).

Disponibilidad y acceso: Los datos son públicos, de acceso libre para investigación y se encuentran disponibles tanto en el repositorio oficial de GroupLens como integrados en los utilitarios de prueba de PyMC.

Estructura de los datos: El conjunto consta de exactamente 100 000 calificaciones asignadas por 943 usuarios a 1 682 películas. Cada usuario en este dataset cuenta con al menos 20 evaluaciones. La variable respuesta es la calificación ordinal $Y_{u,i}$ en la escala discreta {1, 2, 3, 4, 5}.

2. Objetivos del Proyecto

Objetivo General

Construir, implementar y evaluar un modelo bayesiano jerárquico de factorización matricial con términos de sesgo que permita predecir calificaciones de películas no observadas en el dataset MovieLens 100K, cuantificando la incertidumbre asociada tanto a los parámetros latentes como a las distribuciones predictivas posteriores.

Objetivos Específicos

1. Formular el modelo probabilístico jerárquico de factorización matricial, especificando la función de verosimilitud, las distribuciones a priori para los factores latentes y sesgos, y las distribuciones hiper-a priori para los parámetros de escala.

2. Implementar el modelo en Python utilizando la librería PyMC, realizando la inferencia posterior sobre los parámetros mediante algoritmos de simulación MCMC y evaluando la convergencia de las cadenas a través del estadístico R-hat (Gelman-Rubin), el tamaño efectivo de muestra (ESS), la evolución de la norma de Frobenius y la inspección visual de trazados (trace plots).

3. Evaluar el desempeño predictivo posterior del modelo comparando las estimaciones puntuales (media o mediana posterior) mediante métricas de error (RMSE y MAE) sobre el conjunto de prueba, así como la calibración empírica de la incertidumbre mediante la cobertura de los intervalos creíbles al 90 % y 95 %.

4. Analizar el impacto de la estructura jerárquica y la elección de hiper-prioris comparando el modelo propuesto frente a la formulación clásica de varianzas fijas, evaluando su efecto en la mitigación del sobreajuste, la estabilidad de la convergencia y la precisión predictiva general.

3. Plan General del Proyecto

3.1 Justificación y Metodología General

La Factorización Matricial Probabilística (PMF) tradicional representa un avance respecto a la media global o media de medias, sin embargo, su formulación clásica fija de manera determinista las precisiones a priori de los factores latentes y esto limita la capacidad del modelo para adaptarse a la heterogeneidad de los datos, provocando un sobreajuste severo durante el muestreo MCMC.

Para resolver este problema, la metodología corresponde a un enfoque totalmente bayesiano jerárquico (BPMF). Se estructurará un flujo de trabajo cuantitativo en cinco fases:

1. Preprocesamiento y estructuración transductiva: División de la matriz observada en conjuntos de entrenamiento (90 %) y prueba (10 %) conservando los identificadores de usuarios y películas.
2. Formulación del modelo probabilístico jerárquico: Definición de verosimilitudes, prioris y distribuciones hiper-a priori.
3. Inferencia posterior mediante MCMC: Muestreo de la distribución posterior conjunta utilizando algoritmos de Monte Carlo basados en cadenas de Markov en PyMC.
4. Diagnóstico de convergencia: Evaluación cuantitativa de las cadenas muestreadas mediante R-hat, ESS y normas de Frobenius.
5. Evaluación predictiva posterior: Generación de métricas de precisión (RMSE, MAE) e intervalos de credibilidad sobre el conjunto de prueba no observado.

3.2 Formulación preliminar del modelo probabilístico

Variables Observadas:

$Y_{u,i}$ en {1, 2, 3, 4, 5}: Calificación observada asignada por el usuario u (para u = 1, ..., N) a la película i (para i = 1, ..., M).

$I_{u,i}$ en {0, 1}: Variable indicadora de observación (1 si el par (u, i) está observado, 0 en caso contrario).

Parámetros Desconocidos (Latentes):

μ_{global} (en R): Media global de las calificaciones.

b_u (en R^N): Vectores de sesgo individual por usuario (N = usuarios).

b_i (en R^M): Vectores de sesgo individual por película (M = películas).

U_u (en R^D): Matriz de factores latentes de preferencias del usuario u, de dimensión D.

V_i (en R^D): Matriz de factores latentes de atributos de la película i, de dimensión D (número de factores latentes).

$\sigma_y, \sigma_u, \sigma_v, \sigma_{bu}, \sigma_{bi}$ (en R^+): Parámetros de escala y desviación estándar de la verosimilitud y de las distribuciones a priori.

Función de Verosimilitud (Likelihood):

Para cada calificación observada $Y_{u,i}$, la verosimilitud se modela mediante una distribución Gaussiana centrada en la combinación de sesgos y el producto escalar de los factores latentes:

$$Y_{u,i} \sim N(\mu + b_u + b_i + {U_u}^T V_i, \sigma_y^2)$$

Especificación de Distribuciones a Priori e Hiper-a Priori (Priors & Hyperpriors):

A diferencia del modelo base que asigna parámetros fijos, se propone una estructura jerárquica para aprender la escala de la incertidumbre directamente de los datos:

Nivel de Parámetros:

μ_{global} ~ Normal (μ_0, σ_0^2)

b_u | σ_{bu} ~ Normal (0, $\sigma_{bu}{}^2$), para todo u en {1, ..., N}

b_i | σ_{bi} ~ Normal (0, $\sigma_{bi}{}^2$), para todo i en {1, ..., M}

$U_{u,d}$ | σ_u~ Normal (0, σ_u^2), para todo u en {1, ..., N} y d en {1, ..., D}

$V_{i,d}$| σ_v~ Normal (0, σ_v^2), para todo i en {1, ..., M} y d en {1, ..., D}

Nivel Hiper-a Priori (Aparato Jerárquico):

$\sigma_y, \sigma_u, \sigma_v, \sigma_{bu}, \sigma_{bi}$ ~ Half-Normal (sigma = 1.0) o Exponential (lambda = 1.0)

3.3 Herramientas computacionales, métodos de inferencia y evaluación

El proyecto se desarrollará en Python 3.10+, empleando PyMC para la construcción del gráfico acíclico dirigido (DAG) del modelo probabilístico, ArviZ para la inspección diagnóstica y visualización de distribuciones posteriores, NumPy/Pandas para la manipulación matricial de datos dispersos, y Matplotlib/Seaborn para la generación de gráficos.

Métodos de Inferencia:

Aproximación inicial (MAP): Optimización L-BFGS-B sobre la posterior para obtener valores iniciales razonables.

Muestreo MCMC: Uso del algoritmo NUTS (No-U-Turn Sampler) o Muestreador de Gibbs ajustado para extraer muestras de la distribución posterior de las cantidades de interés.

Procedimientos de Evaluación y Diagnóstico:

Convergencia de MCMC: Monitoreo del estadístico de Gelman-Rubin ($\hat{R} < 1.05$), cálculo del tamaño efectivo de muestra (ESS > 400) y seguimiento de la norma de Frobenius $||U||^2_{Fro}$ y $||V||^2_{Fro}$ a lo largo de las cadenas.

Capacidad Predictiva: Evaluación de la media/mediana de la distribución predictiva posterior $Y_{est_{u,i}}$ mediante las métricas RMSE y MAE sobre el conjunto de prueba.

Calibración de la Incertidumbre: Medición empírica del porcentaje de observaciones reales del test que caen dentro de los intervalos creíbles al 90 % y 95 % derivados de las distribuciones predictivas posteriores.

3.4 Referencia del modelo base y propuesta de modificación

Modelo de Referencia Original: Probabilistic Matrix Factorization (PMF) propuesto por Mnih & Salakhutdinov (2008), y la versión adaptada en PyMC por Sweeney, Carroll, Zinkov y Krapu (2026).

Modificación Propuesta: La modificación de este proyecto consiste en implementar una extensión totalmente bayesiana jerárquica con inclusión de términos de sesgo explícitos (b_u, b_i) e hiper-prioris continuas ($\sigma_y, \sigma_u, \sigma_v$). Esta modificación busca evitar la sobre-constricción de los parámetros, mejorar la regularización ante la dispersión de datos y evaluar formalmente si la inferencia jerárquica reduce el sobreajuste reportado en el modelo base durante la inferencia MCMC.

3.5 Cronograma del proyecto

Fase/ Actividad principal	Semana 1	Semana 2	Semana 3	Semana 4	Semana 5	Semana 6	Semana 7

1. Preparación y Exploración de Datos: Carga de MovieLens 100K (ml_100k_u.data), análisis exploratorio y división train/test transductiva (90/10).	X	X					
2.Especificación e Implementación: Formulación probabilística e implementación del gráfico acíclico dirigido (DAG) del modelo BPMF jerárquico en PyMC.		X	X				
3. Inferencia MCMC y Diagnóstico: Muestreo posterior con NUTS, monitoreo de convergencia			X	X			

$\hat{R}$, ESS, trazados y normas de Frobenius).							
4. Evaluación Predictiva y Comparación: Cálculo de RMSE/MAE en el conjunto de prueba, calibración de intervalos creíbles (90 % y 95 %) y comparación vs. PMF básico.				X	X		
5. Informe Final: Consolidación de resultados, análisis de incertidumbre posterior y redacción del documento definitivo.						X	
6. Sustentación del Proyecto: Elaboración de la presentación							X

ejecutiva y defensa oral del proyecto.							

4. Video

Enlace: https://youtu.be/9gyI5JdF458?si=cSa6EMioUnMfpNrm